

Otimização de Interrogações -Candidatos

Trabalho Prático nº 1

Tecnologia de Bases de Dados MIEIC - 2017/2018

Elementos do Grupo:

Andreia Rodrigues - up201404691 - <u>up201404691@fe.up.pt</u> Eduardo Leite - gei12068 - <u>gei12068@fe.up.pt</u>

Index

Objetivo do Trabalho	3
Criação de Índices	3
Metodologia	4
Respostas às Perguntas	4
Pergunta 1 - Seleção e Junção	4
1.1 Formulação SQL	4
1.2 Tempos	4
1.3 Plano de Execução	5
1.4 Resultados	6
1.5 Conclusões	6
Pergunta 2 - Agregação	7
2.1 Formulação SQL	7
2.2 Tempos	7
2.3 Plano de Execução	7
2.4 Resultados	9
2.5 Conclusões	9
Pergunta 3	9
3.1 Formulação SQL	9
3.2 Tempos	10
3.3 Plano de Execução	11
3.4 Resultados	13
3.5 Conclusões	13
Pergunta 4	13
4.1 Formulação SQL	13
4.2 Tempos	15
4.3 Plano de Execução	16
4.4 Resultados	19
4.5 Conclusões	19
Pergunta 5	19
5.1 Formulação SQL	19
5.2 Tempos	20
5.3 Plano de Execução	20
5.4 Resultados	21
5.5 Conclusões	21
Pergunta 6	21
6.1 Formulação SQL	21
6.2 Tempos	22

6.3 Plano de Execução	23
6.4 Resultados	26
6.5 Conclusões	27

Objetivo do Trabalho

O objetivo deste trabalho é analisar os planos de execução de diferentes interrogações SQL a uma BD de teste. Também tem como objetivo avaliar o impacto da existência de índices e do recurso a diferentes estratégias de estruturação das perguntas nas estatísticas.

Criação de Índices

Para as tabelas Z, foram criados 3 índices cujo objetivo foi tornar algumas das interrogações mais rápidas e eficientes. Os índices criados foram os seguintes:

- Bitmap na tabela ZALUS com a coluna "estado" e a operação de subtração entre as colunas "a_lect_conclusao" e "a_lect_matricula". Este índice foi criado para tornar a resposta à primeira questão mais eficiente, reduzindo o custo da mesma de forma significativa. O índice utiliza a coluna "estado" por requerer a identificação do estado do aluno e a operação de subtração é necessária para a obtenção do número total de anos necessários para terminar o curso.
- Btree na tabela ZALUS com as colunas "curso", "a_lect_matricula" e "bi".
 Este índice é vantajoso para várias interrogações, nas quais estas colunas são quase sempre acedidas em conjunto.
- Bitmap na tabela ZCANDS com a coluna "resultado". Este índice faz parte do enunciado da pergunta 5 e foi adicionado por esse propósito, tornando a pergunta em questão muito mais eficiente.

```
CREATE BITMAP INDEX IDX_ZALUS_ESTADO_TEMPOCURSO ON ZALUS (ESTADO,
A_LECT_CONCLUSAO - A_LECT_MATRICULA);

CREATE INDEX IDX_ZALUS_CURSO_MATRICULA_BI ON ZALUS (CURSO, A_LECT_MATRICULA,
BI);

CREATE BITMAP INDEX IDX ZCANDS RESULTADO ON ZCANDS (RESULTADO);
```

Metodologia

Para cada uma das questões feitas no enunciado, o código SQL respetivo foi corrido 3 vezes e o tempo de execução foi registado para fazer uma média dos tempos obtidos para cada query nos diferentes tipos de tabelas (X, Y ou Z).

Foram ainda registados, para cada pergunta, os planos de execução e resultados obtidos.

Respostas às Perguntas

Pergunta 1 - Seleção e Junção

1.1 Formulação SQL

```
SELECT alu.numero AS Aluno, (alu.a_lect_conclusao - alu.a_lect_matricula) AS
Anos
FROM ZALUS alu
JOIN ZLICS lics ON alu.curso = lics.codigo
WHERE lics.sigla = 'EIC'
AND alu.estado = 'C'
AND (alu.a_lect_conclusao - alu.a_lect_matricula) < 5
;</pre>
```

1.2 Tempos

X	Υ	Z
40 ms	40,7 ms	31 ms

Tabela 1 - Tempos de execução relativos à primeira pergunta utilizando as tabelas X, Y e Z.

1.3 Plano de Execução

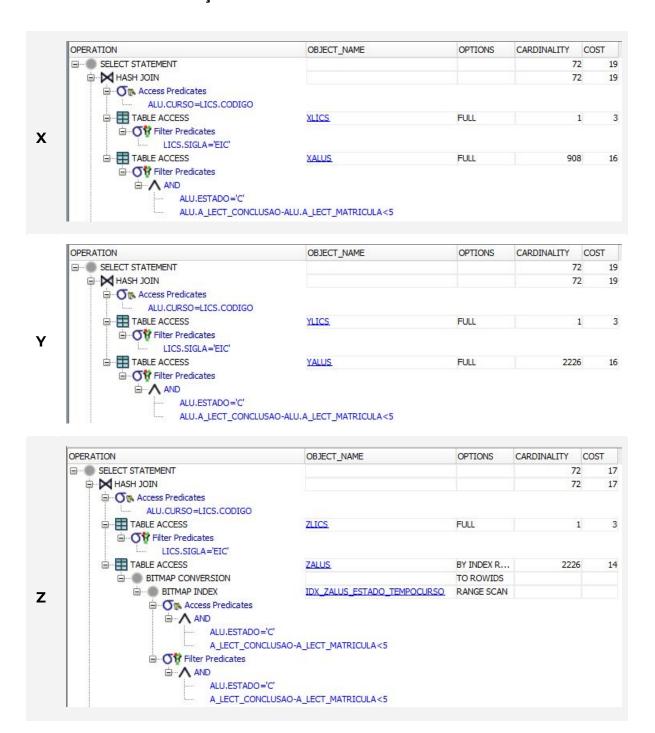


Tabela 2 - Planos de execução relativos à primeira pergunta utilizando as tabelas X, Y e Z.

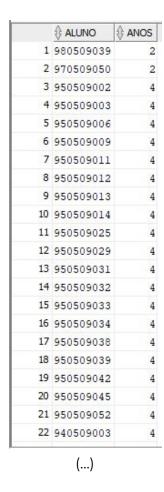


Imagem 1 - Parte dos resultados obtidos relativos à primeira pergunta.

1.5 Conclusões

O grupo concluiu que a existência de restrições de integridade standard (chave primária e chave externa) não tinha impacto significativo nos tempos nem nos planos de execução, mas que a adição de um índice do tipo bitmap nos valores da tabela ALUS que são utilizados pela cláusula where (IDX_ZALUS_ESTADO_TEMPOCURSO) tinha um impacto positivo tanto no tempo como no plano de execução da query.

Pergunta 2 - Agregação

2.1 Formulação SQL

```
SELECT cand.CURSO, cand.ANO_LECTIVO, MIN(cand.MEDIA) MEDIA_MIN FROM ZALUS alu

JOIN ZCANDS cand ON cand.BI = alu.BI AND cand.ANO_LECTIVO = alu.A_LECT_MATRICULA AND cand.CURSO = alu.CURSO

WHERE cand.MEDIA IS NOT NULL

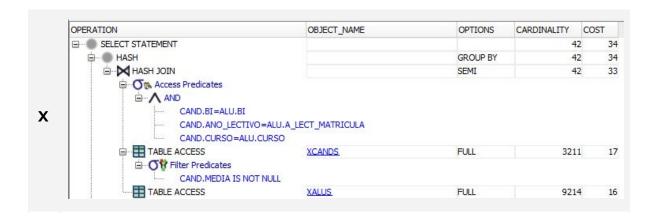
GROUP BY cand.CURSO, cand.ANO_LECTIVO;
```

2.2 Tempos

X	Υ	Z
22 ms	21.3 ms	19 ms

Tabela 3 - Tempos de execução relativos à segunda pergunta utilizando as tabelas X, Y e Z.

2.3 Plano de Execução



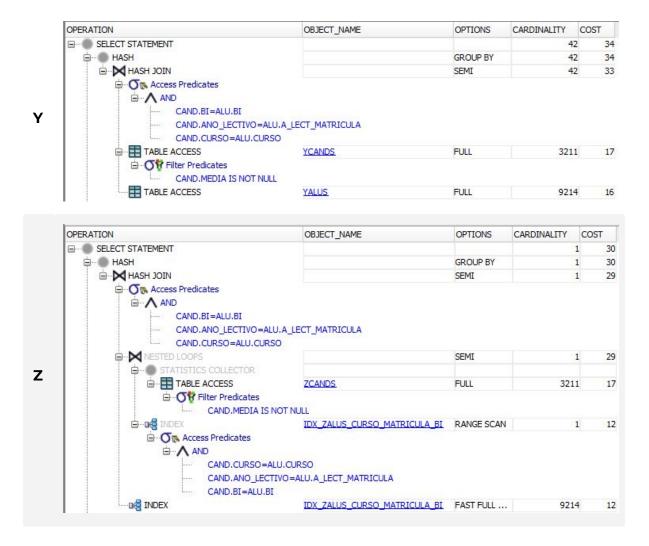


Tabela 4 - Planos de execução relativos à segunda pergunta utilizando as tabelas X, Y e Z.

	CURSO	\$ ANO_LECTIVO	
1	255	1996	14,08
2	255	2000	11,5
3	304	2002	12,23
4	315	2002	10,88
5	433	2001	14,6
6	255	1997	13
7	275	2001	10,2
8	433	2002	15,18
9	649	1998	13
10	1093	2002	12,68
11	233	1998	11
12	233	2001	12
13	304	1994	13
14	315	2001	11,15
15	331	2000	10,38
16	649	2000	11,33
17	233	2002	12,75
18	275	2000	11,5

(...)

Imagem 2 - Parte dos resultados obtidos relativos à segunda pergunta.

2.5 Conclusões

O grupo concluiu que a existência de restrições de integridade standard (chave primária e chave externa) não tinha impacto significativo nos tempos nem nos planos de execução, mas que a adição de um índice do tipo btree nos valores da tabela ALUS que são utilizados para fazer join com a tabela CANDS (IDX_ZALUS_CURSO_MATRICULA_BI) tinha um impacto positivo tanto no tempo como no plano de execução da query.

Pergunta 3

3.1 Formulação SQL

-- Varying Solution

SELECT COUNT(*) AS NAO MATRICULADOS

```
FROM ZCANDS cand
WHERE
cand.RESULTADO = 'C' AND
NOT EXISTS
    SELECT alu.BI
    FROM ZALUS alu
   WHERE
    alu.A LECT MATRICULA = cand.ANO LECTIVO AND
   alu.BI = cand.BI AND
    alu.CURSO = cand.CURSO
)
-- Constant Solution
SELECT COUNT(*) NAO MATRICULADOS
FROM ZCANDS cand
WHERE resultado='C' AND
(BI, ano_lectivo, curso) NOT IN
SELECT alu.BI, alu.a_lect_matricula, alu.curso
FROM ZALUS alu
);
```

3.2 Tempos

3.2.1 Subpergunta Variável

X	Y	Z
21 ms	20 ms	16 ms

Tabela 5 - Tempos de execução relativos à query com subpergunta variável para a terceira pergunta utilizando as tabelas X, Y e Z.

3.2.2 Subpergunta Constante

X	Υ	Z
56 ms	55.3 ms	55ms

Tabela 6 - Tempos de execução relativos à query com subpergunta constante para a terceira pergunta utilizando as tabelas X, Y e Z.

3.3 Plano de Execução

3.3.1 Varying Solution

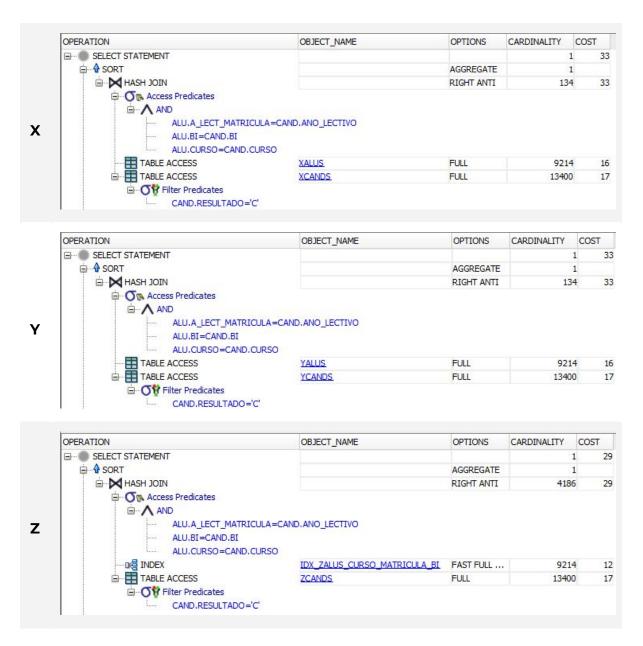
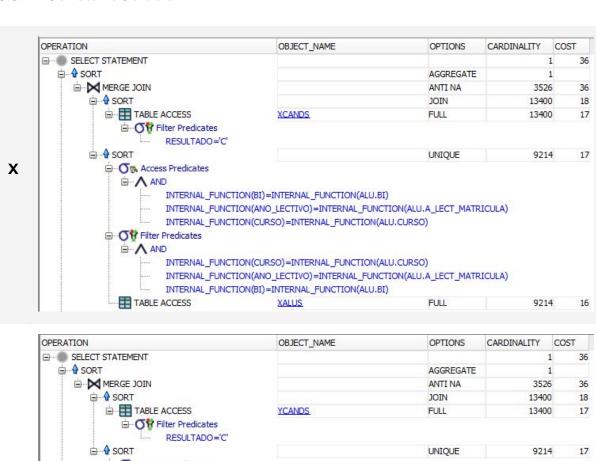
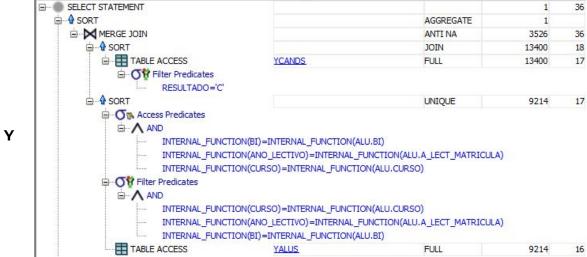


Tabela 7 - Planos de execução relativos à query com subpergunta variável para a terceira pergunta utilizando as tabelas X, Y e Z.

3.3.2 Constant Solution





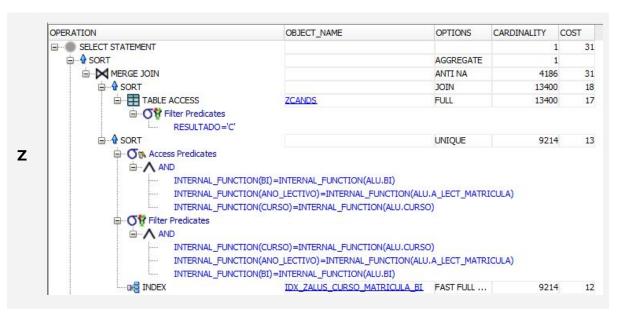


Tabela 8 - Planos de execução relativos à query com subpergunta constante para a terceira pergunta utilizando as tabelas X, Y e Z.

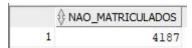


Imagem 3 - Resultado obtido relativo à terceira pergunta (ambas as soluções retornam o mesmo resultado).

3.5 Conclusões

O grupo concluiu que para ambas as soluções a existência de restrições de integridade standard (chave primária e chave externa) não tinha impacto significativo nos tempos nem nos planos de execução, mas que a adição de um índice do tipo btree nos valores da tabela ALUS que são utilizados pela cláusula "where" (IDX_ZALUS_CURSO_MATRICULA_BI) tinha um impacto positivo tanto no tempo como no plano de execução da query.

Também concluímos que a solução variável tem um tempo de execução menor e um plano de execução menos custoso do que a solução constante.

Pergunta 4

4.1 Formulação SQL

```
-- Greatest n per group problem
-- Solution 1, Join with Group-Identifier Max-value-in-Group Subquery

SELECT t1.*

FROM
(
SELECT A_LECT_CONCLUSAO, CURSO, AVG_MED_FINAL

FROM
(
SELECT alu.A_LECT_CONCLUSAO, alu.CURSO, AVG(alu.MED_FINAL) AVG_MED_FINAL

FROM XALUS alu

WHERE alu.MED_FINAL IS NOT NULL

GROUP BY alu.A_LECT_CONCLUSAO, alu.CURSO
)
```

```
) t1
INNER JOIN
SELECT A LECT CONCLUSAO, MAX(AVG MED FINAL) MAX AVG MEDIA FINAL
SELECT A LECT CONCLUSAO, CURSO, AVG MED FINAL
(
SELECT alu.A LECT CONCLUSAO, alu.CURSO, AVG(alu.MED FINAL) AVG MED FINAL
FROM XALUS alu
WHERE alu.MED FINAL IS NOT NULL
GROUP BY alu.A LECT CONCLUSAO, alu.CURSO
ORDER BY alu.A LECT CONCLUSAO, alu.CURSO
)
)
GROUP BY A LECT CONCLUSAO
) t2 ON t1.A LECT CONCLUSAO = t2.A LECT CONCLUSAO AND t1.AVG MED FINAL =
t2.MAX AVG MEDIA FINAL
ORDER BY t1.A LECT CONCLUSAO
-- Solution 2, Left Join Self using join conditions
SELECT t1.*
FROM
SELECT A LECT CONCLUSAO, CURSO, AVG MED FINAL
FROM
SELECT alu.A LECT CONCLUSAO, alu.CURSO, AVG(alu.MED FINAL) AVG MED FINAL
FROM XALUS alu
WHERE alu.MED FINAL IS NOT NULL
GROUP BY alu.A LECT CONCLUSAO, alu.CURSO
ORDER BY alu.A LECT CONCLUSAO, alu.CURSO
)
)
t1
LEFT OUTER JOIN
SELECT A LECT CONCLUSAO, CURSO, AVG MED FINAL
FROM
SELECT alu.A LECT CONCLUSAO, alu.CURSO, AVG(alu.MED FINAL) AVG MED FINAL
FROM XALUS alu
WHERE alu.MED FINAL IS NOT NULL
GROUP BY alu.A LECT CONCLUSAO, alu.CURSO
ORDER BY alu.A LECT CONCLUSAO, alu.CURSO
)
```

```
t2 ON (t1.A_LECT_CONCLUSAO = t2.A_LECT_CONCLUSAO AND t1.AVG_MED_FINAL < t2.AVG_MED_FINAL)
WHERE t2.A_LECT_CONCLUSAO IS NULL
ORDER BY t1.A_LECT_CONCLUSAO;
```

4.2 Tempos

4.2.1 Primeira Solução

X	Y	z
16 ms	17 ms	16 ms

Tabela 9 - Tempos de execução relativos à primeira solução elaborada para a quarta pergunta utilizando as tabelas X, Y e Z.

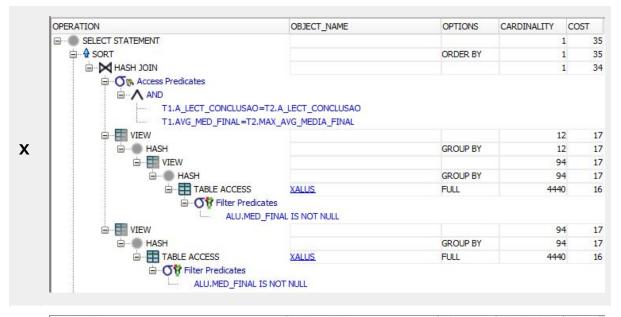
4.2.2 Segunda Solução

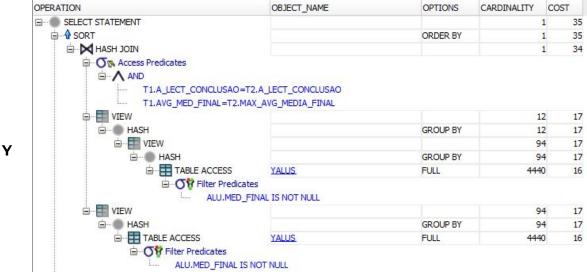
X	Υ	Z
18 ms	18 ms	17 ms

Tabela 10 - Tempos de execução relativos à segunda solução elaborada para a quarta pergunta utilizando as tabelas X, Y e Z.

4.3 Plano de Execução

4.3.1 Primeira Solução





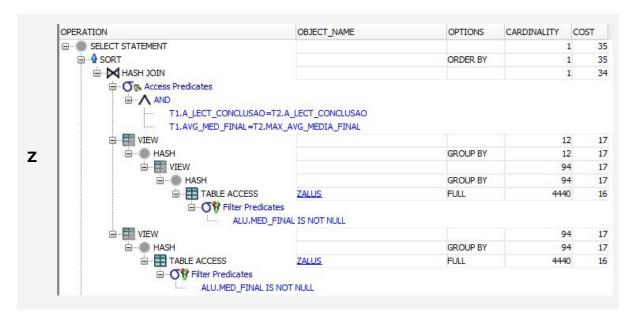
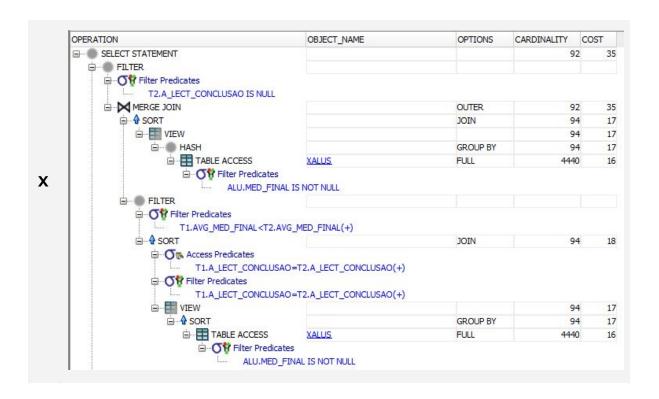
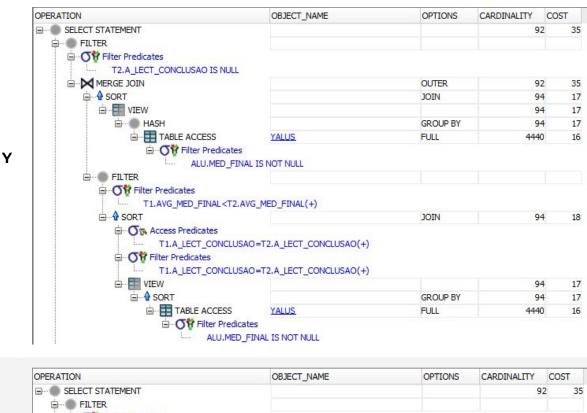


Tabela 11 - Planos de execução relativos à primeira solução elaborada para a quarta pergunta utilizando as tabelas X, Y e Z.

4.3.2 Segunda Solução





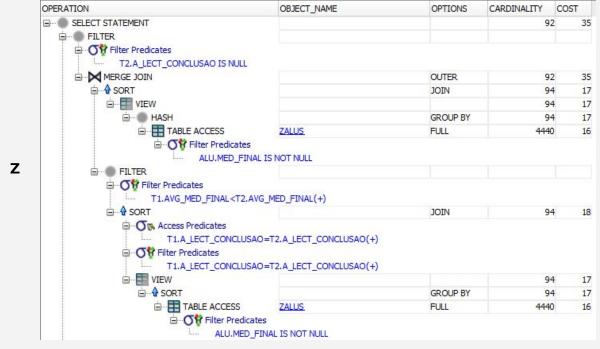


Tabela 12 - Planos de execução relativos à segunda solução elaborada para a quarta pergunta utilizando as tabelas X, Y e Z.

			♦ AVG_MED_FINAL
1	1988	304	11
2	1990	233	12
3	1992	255	13,1061946902654867256637168141592920354
4	1993	331	13,42857142857142857142857142857142857143
5	1994	433	13,90909090909090909090909090909090909090
6	1995	433	14,22727272727272727272727272727272727272
7	1996	433	13,90909090909090909090909090909090909090
8	1997	433	13,3988888888888888888888888888888888888
9	1998	275	14,3513043478260869565217391304347826087
10	1999	433	14,1633333333333333333333333333333333333
11	2000	275	14,015
12	2001	433	13,496

Imagem 4 - Resultados obtidos relativos à quarta pergunta (ambas as soluções retornam os mesmos resultados).

4.5 Conclusões

O grupo concluiu que para ambas as soluções nem a existência de restrições de integridade standard (chave primária e chave externa) nem dos índices adicionados, tinha impacto significativo nos tempos nem nos planos de execução.

Também concluímos que ambas as soluções têm tempos e planos de execução praticamente equivalentes.

Pergunta 5

5.1 Formulação SQL

```
SELECT count(*) candidatos
FROM ZCANDS cand
WHERE cand.RESULTADO != 'C' AND cand.RESULTADO != 'E';
```

5.2 Tempos

x	Y	Z bitmap	Z btree
5 ms	5.3 ms	3 ms	3 ms

Tabela 13 - Tempos de execução relativos à quinta pergunta utilizando as tabelas X, Y e Z.

5.3 Plano de Execução

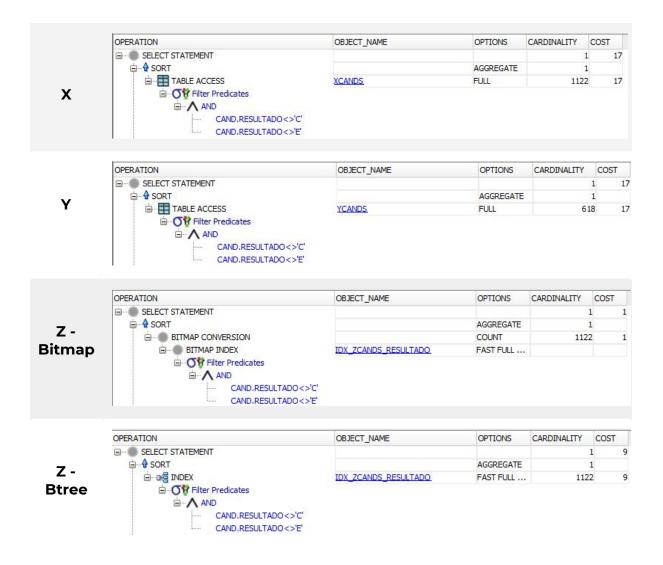


Tabela 14 - Planos de execução relativos à quinta pergunta utilizando as tabelas X, Y e Z (com índices bitmap e btree).



Imagem 5 - Resultados obtidos relativos à quinta pergunta.

5.5 Conclusões

O grupo concluiu que a existência de restrições de integridade standard (chave primária e chave externa) não tinha impacto significativo nos tempos nem nos planos de execução, mas que a adição de um índice do tipo bitmap ou btree na coluna resultado da tabela CANDS que é utilizada pela cláusula "where" (IDX_ZCANDS_RESULTADO) tinha um impacto positivo tanto no tempo como no plano de execução da query.

Também concluímos que o índice do tipo bitmap tem um impacto superior ao índice do tipo btree tanto no tempo como no plano de execução da query, pelo que adoptamos o primeiro. Atribuímos a razão desta vantagem do índice bitmap sobre o índice btree ao facto de a coluna em questão ter baixa cardinalidade (3).

Pergunta 6

6.1 Formulação SQL

```
-- Double Negation

SELECT cand.ANO_LECTIVO, cand.CURSO, lics.SIGLA, lics.NOME
FROM ZCANDS cand

JOIN ZLICS lics ON lics.CODIGO = cand.CURSO
WHERE cand.RESULTADO = 'C' AND

(ANO_LECTIVO, CURSO) NOT IN

(
SELECT cand.ANO_LECTIVO, cand.CURSO
FROM ZCANDS cand
WHERE cand.RESULTADO = 'C' AND
NOT EXISTS

(
SELECT *
FROM ZALUS alu
WHERE alu.A_LECT_MATRICULA = cand.ANO_LECTIVO AND
alu.BI = cand.BI AND
```

```
alu.CURSO = cand.CURSO
GROUP BY cand.ANO_LECTIVO, cand.CURSO
GROUP BY cand. ANO LECTIVO, cand. CURSO, lics. SIGLA, lics. NOME
-- Count
SELECT cands.ANO LECTIVO, cands.CURSO, lics.SIGLA, lics.NOME
SELECT cands.ANO LECTIVO, cands.CURSO, count(*) CANDIDATURAS
FROM ZCANDS cands
WHERE cands.RESULTADO = 'C'
GROUP BY cands. ANO LECTIVO, cands. CURSO
) cands
JOIN
SELECT A_LECT_MATRICULA, CURSO, MATRICULAS
SELECT alu.A LECT MATRICULA, alu.CURSO, count(*) MATRICULAS
FROM ZALUS alu
GROUP BY alu.A_LECT_MATRICULA, alu.CURSO
) alu ON alu.A LECT MATRICULA = cands.ANO LECTIVO AND alu.CURSO = cands.CURSO
JOIN ZLICS lics ON lics.CODIGO = cands.CURSO
WHERE
CANDIDATURAS = MATRICULAS
```

6.2 Tempos

6.2.1 Dupla Negação

X	Υ	Z
36 ms	35 ms	33 ms

Tabela 15 - Tempos de execução relativos à solução que utiliza dupla negação para a sexta pergunta utilizando as tabelas X, Y e Z.

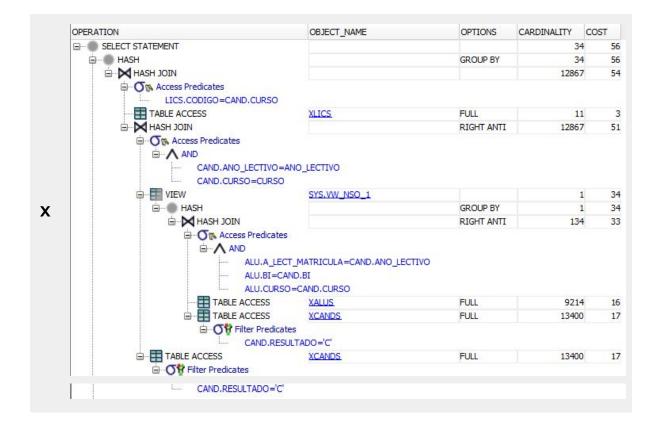
6.2.2 Contagem

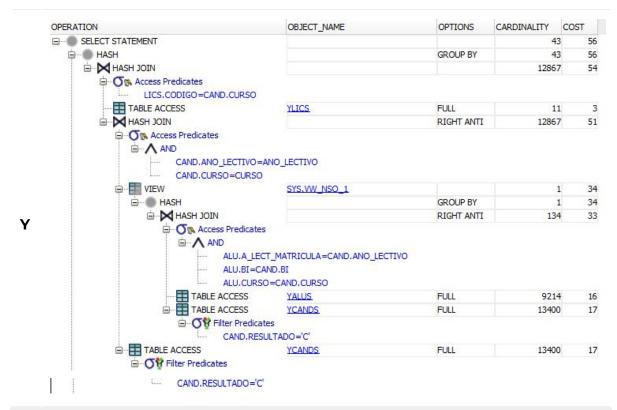
X	Y	z
14 ms	14 ms	13 ms

Tabela 16 - Tempos de execução relativos à solução que utiliza contagem para a sexta pergunta utilizando as tabelas X, Y e Z.

6.3 Plano de Execução

6.3.1 Dupla Negação





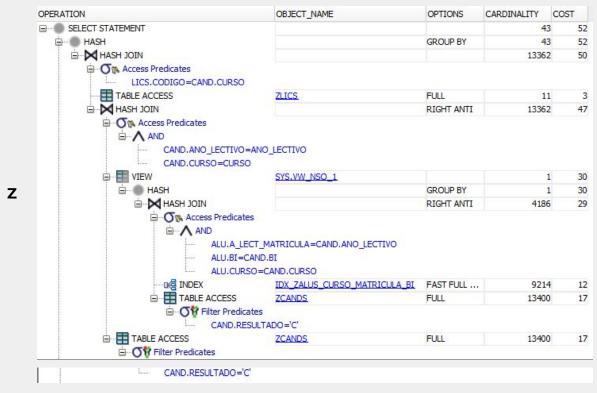
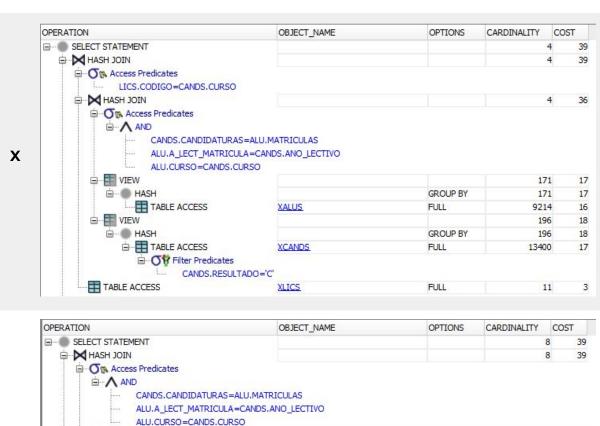


Tabela 17 - Planos de execução relativos à solução que utiliza dupla negação para a sexta pergunta utilizando as tabelas X, Y e Z.

6.3.2 Contagem





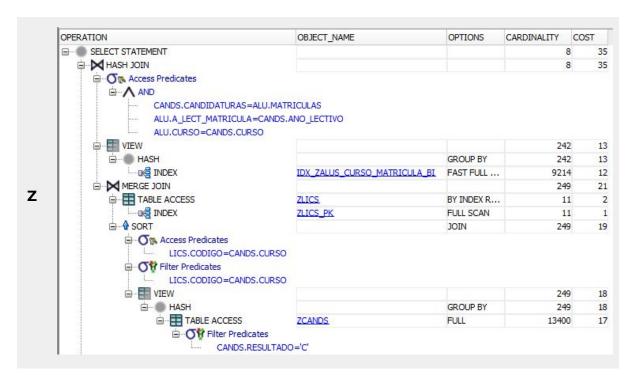


Tabela 18 - Planos de execução relativos à solução que utiliza contagem para a sexta pergunta utilizando as tabelas X, Y e Z.

	\$ ANO_LECTIVO	♦ CURSO	♦ SIGLA	NOME NOME
1	2001	318	EMI	Engenharia de Minas
2	1970	233	EC	Engenharia Civil
3	1974	304	EM	Engenharia Mecânica
4	1983	315	EMM	Engenharia Metalúrgica e de Materiais
5	1984	315	EMM	Engenharia Metalúrgica e de Materiais
6	1996	649	EMG	Engenharia de Minas e Geoambiente
7	1980	304	EM	Engenharia Mecânica
8	1977	304	EM	Engenharia Mecânica
9	1972	233	EC	Engenharia Civil
10	1982	315	EMM	Engenharia Metalúrgica e de Materiais
11	1981	312	EMT	Engenharia Metalúrgica

Imagem 6 - Resultados obtidos relativos à sexta pergunta (ambas as soluções retornam os mesmos resultados).

6.5 Conclusões

O grupo concluiu que para ambas as soluções a existência de restrições de integridade standard (chave primária e chave externa) não tinha impacto significativo nos tempos nem nos planos de execução, mas que a adição de um índice do tipo btree nos valores da tabela ALUS que são utilizados pela cláusula "where" na primeira opção e pelo "join" na segunda opção (IDX_ZALUS_CURSO_MATRICULA_BI) tinha um impacto positivo tanto no tempo como no plano de execução da query.

Também concluímos que a solução com contagem tem um tempo de execução menor e um plano de execução menos custoso do que a solução com dupla negação.